

Implementación de YOLOv8 Small y MobileNet V3 Large para la Identificación y Clasificación de Aves en Dispositivos Móviles en un Sistema Automatizado de Muestreo

Axel Frederick Félix Jiménez
Ingeniería en Sistemas Computacionales
Instituto Politécnico Nacional
Zacatecas, México
afelixj2000@alumno.ipn.mx

Vania Stephany Sánchez Lee
Ingeniería en Sistemas Computacionales
Instituto Politécnico Nacional
Zacatecas, México
vsanchezl2000@alumno.ipn.mx

Abstract—Este trabajo expone la implementación de YOLOv8 Small y MobileNet V3 para la identificación y clasificación de aves de la ciudad de Zacatecas, muestreando 5 tipos de aves (Papamoscas Cardenalito, Papamoscas Pinero, Carpintero de Arizona, Carbonero Mexicano y Zacatonero Serrano). Con la finalidad de automatizar el sistema de muestreo utilizado por los biólogos de la Universidad Autónoma de Zacatecas.

Index Terms—YOLOv8 Small, MobileNet V3, TensorFlow Lite, clasificación de aves, muestreo automatizado, aplicación móvil.

I. INTRODUCCIÓN

Actualmente, los investigadores del área de biología de la Universidad Autónoma de Zacatecas (UAZ) llevan a cabo sus muestreos de aves siguiendo un manual que estandariza el proceso. Sin embargo, este enfoque implica un considerable consumo de tiempo, ya que incluye la instalación de equipos de investigación que el mismo manual especifica como necesarios [1]. Este procedimiento puede tomar varias horas para completar un solo muestreo.

En este contexto, existen tecnologías que podrían optimizar y simplificar este proceso. Por ejemplo, las redes neuronales tienen un gran potencial en el reconocimiento de objetos en imágenes [2]. La implementación de YOLOv8 Small, junto con su librería Ultralytics, resulta especialmente adecuada gracias a su compatibilidad con dispositivos móviles, lo que permite identificar aves en imágenes de manera más eficiente [3]. Además, el uso de la red neuronal MobileNet V3 complementa este sistema para la clasificación de las aves detectadas, permitiendo distinguir entre diferentes especies de forma precisa y rápida [4]. Esto permite a los investigadores ahorrar tiempo en sus investigaciones.

Estas tecnologías tienen como objetivo implementarse en dispositivos móviles Android de gama media-alta, permitiendo a los investigadores llevar a cabo sus muestreos de manera más portátil, rápida y menos invasiva para las aves. Al eliminar la necesidad de instalar equipos mencionados en el manual, como trampas o redes, el proceso se limita al uso de la cámara de un teléfono móvil, reduciendo el impacto sobre el entorno natural

de las aves y optimizando los recursos empleados en el trabajo de campo.

Para este proyecto, se seleccionaron cinco especies específicas para su identificación y clasificación: el Papamoscas Cardenalito, el Papamoscas Pinero, el Zacatonero Serrano, el Carpintero de Arizona y el Carbonero Mexicano. La selección de estas aves responde a criterios específicos: todas son aves endémicas o semiendémicas de la región de Zacatecas, y además presentan características distintivas en comparación con otras aves locales, como patrones de plumaje y formas corporales únicas, lo que facilita su clasificación mediante redes neuronales [5]. Adicionalmente, estas especies son representativas del ecosistema local y su monitoreo contribuye significativamente a los estudios de biodiversidad en la región. El periodo de desarrollo del proyecto se estableció en tres meses, en concordancia con los objetivos definidos por el patrocinador y las restricciones de recursos disponibles. Este límite temporal guió la selección de las especies, priorizando aquellas que permitieran implementar una solución eficiente dentro del plazo estipulado.

II. TRABAJOS RELACIONADOS

La detección y clasificación de aves han sido áreas de interés en proyectos debido a su relevancia en el monitoreo ambiental [6]. Estos trabajos emplean técnicas avanzadas como redes neuronales convolucionales (CNNs) y transferencia de aprendizaje, así como su aplicación en dispositivos portátiles, como teléfonos móviles y drones, con la finalidad de probarse en entornos naturales.

Sin embargo, los estudios existentes enfrentan retos como la necesidad de conjuntos de datos más representativos, la identificación precisa de aves y la optimización de modelos para dispositivos con recursos limitados. A continuación, en la Tabla I, se presenta una comparación de los enfoques empleados en estudios recientes para la detección y clasificación de aves.

TABLE I
COMPARACIÓN DE ESTUDIOS RELACIONADOS EN DETECCIÓN Y
CLASIFICACIÓN DE AVES

Artículo	Método de Detección	Clasificación	Ventajas	Limitaciones
Acoustic detection of regionally rare bird species through deep convolutional neural networks [7]	DCNNs adaptadas	No aplica	Generalización acústica mediante aumento de datos	No aborda imágenes, enfoque exclusivo en audio
Bird Detection and Species Classification: Using YOLOv5 and Deep Transfer Learning Models [8]	YOLOv5	VGG19, Inception V3, EfficientNetB3	Detección robusta, clasificación precisa de especies	Requiere datasets grandes y alto costo computacional
DeepVision: Enhanced Drone Detection and Recognition in Visible Imagery through Deep Learning Networks [9]	YOLO, Faster R-CNN	No aplica	Uso eficiente de UAVs (vehículo aéreo no tripulado) para monitoreo en hábitats	Dificultades con la detección de objetos menores a 40 × 40 píxeles y en movimiento.
Automating Bird Detection Based on Webcam Captured Images using Deep Learning [10]	Faster R-CNN, SSD	No aplica	Transferencia de aprendizaje con conjuntos preentrenados	No clasifica especies, limitado a cámaras web
Bird monitoring using the smartphone (iOS) application Videography for motion detection [11]	Movimiento con smartphones	No aplica	Uso de hardware accesible	Limitado a detección cercana
Advanced Computer Vision Methods for Tracking Wild Birds from Drone Footage [12]	YOLOv7, YOLOv8	No aplica	Optimización para objetos pequeños con drones	Alta complejidad computacional

Analizando la información de la Tabla I, se observa que la mayoría de los proyectos realizados se centran en la identificación de especies, pero no en su clasificación. De los seis proyectos analizados, destaca el titulado "Bird Detection and Species Classification: Using Yolov5 and Deep Transfer Learning Models", el cual implementa tanto un modelo de identificación como de clasificación, utilizando tecnologías como YOLOv5, Inception V3 y EfficientNetB3 [13]. Al centrarnos en sus ventajas y limitaciones, se concluye que estas implementaciones ofrecen una detección robusta y una clasificación precisa de especies. Sin embargo, para alcanzar los altos niveles de precisión reportados, es necesario contar con un conjunto de datos extenso, además de enfrentar costos elevados asociados al entrenamiento de los modelos de redes neuronales.

En cuanto a los proyectos analizados en la Tabla I que utilizan la tecnología YOLO, la mayoría se limita a la "identificación" de objetos de interés, sin abordar la "clasificación" de los mismos. Además, estas implementaciones suelen integrarse en dispositivos como drones, UAVs (vehículo aéreo no tripulado) y cámaras web. Por otro lado, el artículo "Bird Monitoring Using the Smartphone (iOS) Application Videography for Motion Detection" guarda relación con nuestro enfoque de utilizar redes neuronales en dispositivos móviles para la identificación de aves. Este artículo describe el uso de una aplicación llamada "Videography", que emplea un algoritmo diseñado para detectar cambios de píxeles en el campo visual de la cámara [14].

III. METODOLOGÍA

El objetivo de este proyecto es satisfacer la necesidad de los investigadores del área de biología de automatizar el proceso de muestreo de aves. Para lograrlo, se busca habilitar un dispositivo móvil Android de gama media-alta para identificar y clasificar especies de aves. Las especies objetivo para la clasificación incluyen el Papamoscas Cardenalito, el Papamoscas Piñero, el Zacatonero Serrano, el Carpintero de Arizona y el Carbonero Mexicano.

Se llevó a cabo una investigación preliminar con el objetivo de seleccionar el modelo de clasificación más adecuado para este proyecto, enfocado en identificar cinco especies específicas de aves. Durante el proceso, se evaluaron tres modelos de redes neuronales: ResNet34, Inception v3 y MobileNet v3. Los resultados indicaron que MobileNet v3 era la opción más adecuada, alcanzando una precisión del 94.46%.

Además, el estudio destacó que el diseño de MobileNet v3 está especialmente optimizado para su implementación en dispositivos móviles, lo que lo convierte en un candidato ideal para este proyecto. La implementación del modelo permitirá, a partir de una fotografía o imagen capturada con un teléfono móvil o dispositivo similar, clasificar el ave en una de las siguientes especies: papamoscas piñero, papamoscas cardenalito, carbonero mexicano, carpintero de Arizona y zacatonero serrano, como se ilustra en la figura 1.




Fig. 1. Descripción gráfica del proceso de clasificación de aves utilizando MobileNetV3.

Para seleccionar el modelo o red neuronal más adecuada para la identificación de aves, se llevó a cabo una investigación que concluyó que YOLOv8 era la opción más óptima para su implementación en dispositivos móviles. Según el artículo titulado "A Review on YOLOv8 and Its Advancement", el diseño compacto y eficiente de YOLOv8 facilita su adaptación a plataformas de hardware de gama media o baja [15]. Asimismo, esta investigación destaca que las versiones escaladas, como YOLOv8s (Small), están específicamente diseñadas para operar en entornos con recursos limitados, como smartphones y dispositivos embebidos [16].

Por esta razón, se decidió implementar YOLOv8 Small como modelo para la identificación de aves. El proceso consiste en utilizar YOLOv8 Small para detectar un ave en una imagen, recortar el área donde se encuentra dicha ave y enviarla al modelo de clasificación MobileNet V3. Este flujo de trabajo, representado en la Fig. 2, tiene como objetivo optimizar el rendimiento del modelo de clasificación al proporcionar una imagen recortada únicamente del área que contiene el ave.



Fig. 2. Descripción gráfica del proceso de identificación de aves utilizando YOLOv8 Small

De esta manera, se reduce la necesidad de analizar elementos externos en la imagen, permitiendo que el modelo se enfoque exclusivamente en el ave, lo que agiliza y simplifica el reconocimiento.

A continuación, se detalla el proceso seguido para implementar las tecnologías en el proyecto, incluyendo los métodos empleados para la preparación de datos, selección de modelos, estrategias de entrenamiento, y evaluación de resultados, así como los desafíos encontrados y las estrategias empleadas para superarlos.

A. Dataset Preparation

1) *Dataset para YOLOv8 Small*: Para el entrenamiento de la red neuronal Yolo v8 se eligió el dataset titulado "Bird Detection Computer Vision Project" [16], disponible en la plataforma Roboflow. Este dataset fue seleccionado debido a su gran variedad de imágenes que representan aves en distintos entornos, lo que resulta un modelo más robusto para detección.

Los porcentajes de división para entrenamiento (84%), validación (11%) y prueba (6%) se mantuvieron según la configuración original del dataset. Esta división sigue las recomendaciones de la literatura en aprendizaje profundo, donde se sugiere destinar más del 80% de los datos al entrenamiento para garantizar una adecuada capacidad de generalización del modelo [17]. No se realizaron modificaciones en esta división para evitar introducir sesgos y para aprovechar la distribución óptima diseñada por los autores del dataset.

El dataset contiene un total de 14,162 imágenes de aves, distribuidas en las carpetas de entrenamiento, validación y prueba. La Tabla II muestra los detalles de esta división.

TABLE II
DIVISIÓN DEL DATASET YOLO. DISTRIBUCIÓN DE IMÁGENES PARA ENTRENAMIENTO, VALIDACIÓN Y PRUEBA.

Dataset Split	Percentage	Number of Images
Train Set	84%	11,850
Valid Set	11%	1,521
Test Set	6%	791

2) *Dataset para MobileNet V3*: El uso de MobileNet V3 es para la clasificación de las aves identificadas por medio de una imagen tomada por la cámara del celular o cargada desde el mismo. Como ya se mencionó las aves a clasificar son 5 (Papamoscas Cardenalito, Zacatonero Serrano, Papamoscas Pinero, Carbonero Mexicano, Carpintero de Arizona), tal y como se muestra en la Figura 3.




Fig. 3. Aves a clasificar. Ejemplos de las cinco especies objetivo.

El proceso de creación del dataset siguió un enfoque iterativo para mejorar su calidad y representatividad. A continuación, se describen las tres versiones generadas:

- **Dataset Básico**: Compuesto por 2,500 imágenes por clase (12,500 en total). Este conjunto inicial carecía de técnicas de preprocesamiento avanzadas, lo que resultó en una baja diversidad y limitaciones en la capacidad de generalización del modelo.
- **Dataset Ampliado**: Incrementó a 5,000 imágenes por clase (25,000 en total), incluyendo técnicas de aumento de datos (*data augmentation*), como rotaciones, recortes y cambios de brillo. Aunque esto mejoró la diversidad, se observó sobreajuste en ciertas clases.
- **Dataset Balanceado y Limpio**: Se consolidó a 3,000 imágenes por clase (15,000 en total), seleccionando las imágenes de mayor calidad y eliminando aquellas redundantes. Este ajuste equilibró eficiencia y representatividad, optimizando el desempeño del modelo.

La progresión de la cantidad de imágenes en cada iteración se ilustra en la Figura 4.




Fig. 4. Cantidad de imágenes. Progresión del número de imágenes por clase en el dataset final.

Para clarificar las características de las imágenes utilizadas en el dataset, se definen los siguientes términos clave:

- **Imágenes con ruido:** Contienen interferencias o patrones visuales externos que pueden dificultar la identificación, simulando condiciones reales.
- **Imágenes rotadas:** Modificadas mediante giros angulares para aumentar la diversidad y mejorar la robustez del modelo frente a cambios de orientación.
- **Imágenes con zoom:** Escaladas para simular acercamientos y mejorar la capacidad del modelo para identificar objetos a diferentes distancias.
- **Imágenes sin fondo:** Procesadas para eliminar el entorno de fondo y enfocar únicamente el objeto principal, en este caso, las aves.

La evolución del dataset permitió mejorar progresivamente la calidad de los datos, comenzando con imágenes básicas en el *Dataset Básico* y añadiendo técnicas como rotaciones, recortes y zoom en el *Dataset Ampliado*. Finalmente, el *Dataset Balanceado y Limpio* priorizó imágenes sin fondo y de mayor calidad, consolidando un conjunto robusto para el entrenamiento del modelo. Estas mejoras se resumen en la Tabla III.

TABLE III
COMPARACIÓN DE CARACTERÍSTICAS EN LOS DATASETS. MEJORAS PROGRESIVAS EN LA CALIDAD DE LOS DATOS UTILIZADOS.

Características	Dataset Básico	Dataset Ampliado	Dataset Balanceado y Limpio
Imágenes con ruido	✓	✓	✓
Imágenes rotadas		✓	
Imágenes con zoom		✓	
Imágenes sin fondo		✓	✓
Imágenes con mayor calidad			✓

B. Entrenamiento de MobileNet V3

Para evaluar el desempeño de MobileNet V3, se llevaron a cabo tres experimentos, cada uno utilizando una versión distinta del conjunto de datos (Dataset Básico, Dataset Ampliado, Dataset Balanceado y Limpio). Cada experimento permitió probar diferentes configuraciones y ajustar tanto la cantidad como la calidad de los datos para optimizar el modelo.

Los tres entrenamientos fueron diseñados para explorar cómo las características del dataset y las configuraciones de entrenamiento influían en el desempeño del modelo. A continuación, se describen las técnicas y configuraciones clave utilizadas en los experimentos:

- **Transferencia de Aprendizaje:** Técnica en aprendizaje profundo que utiliza un modelo previamente entrenado en una tarea como punto de partida para otra tarea relacionada. Por ejemplo, un modelo entrenado en millones de imágenes puede ajustarse a un nuevo conjunto de datos más pequeño, aprovechando los patrones ya aprendidos.
- **Data Augmentation:** Consiste en aumentar la cantidad y diversidad de datos de entrenamiento aplicando transformaciones a los datos existentes, como rotaciones,

recortes, cambios de brillo, o adiciones de ruido. Esto mejora la generalización del modelo al simular variaciones que podrían encontrarse en el mundo real.

- **Dropout:** Técnica de regularización en redes neuronales que consiste en desactivar aleatoriamente algunas neuronas durante el entrenamiento. Esto previene el sobreajuste y mejora la capacidad de generalización del modelo.
- **Descongelamiento de Capas:** Proceso de liberar las capas de un modelo previamente entrenado (congeladas para mantener sus pesos fijos) para permitir que sean ajustadas durante el entrenamiento en una nueva tarea. Esto es común en transferencia de aprendizaje para adaptar modelos preentrenados a datos específicos.

TABLE IV
COMPARACIÓN DE CONFIGURACIONES EN LOS ENTRENAMIENTOS. TÉCNICAS EMPLEADAS EN TRES ENTRENAMIENTOS DE MOBILENET V3.

Características	Entrenamiento 1	Entrenamiento 2	Entrenamiento 3
Transferencia de aprendizaje	✓	✓	✓
Data augmentation	✓	✓	✓
Dropout		✓	✓
Descongelamiento de capas			✓

Con base a la Tabla IV, que muestra las diferentes métricas implementadas durante el entrenamiento del modelo, se observa que la mejor configuración para la clasificación de las cinco aves fue aquella en la que se descongelaron las capas del modelo. El descongelamiento de capas permite que el modelo se adapte específicamente al conjunto de datos con el cual es entrenado, ya que, por defecto, MobileNet V3 utiliza los pesos preentrenados de ImageNet como punto de partida [18].

Es importante mencionar que, en los tres entrenamientos realizados, cada uno utilizó diferentes cantidades de imágenes, como se explicó anteriormente. Dado que este enfoque era experimental, se estableció un límite de 100 épocas para cada entrenamiento, con el objetivo de identificar en qué punto el modelo dejaba de mejorar significativamente. Esta estrategia permitió evaluar el comportamiento del modelo y determinar el entrenamiento más efectivo.




Fig. 5. Numero de Epocas de Entrenamiento de Mobilenet V3

Cada versión del dataset (Dataset Basico, Dataset Ampliado, Dataset Balanceado y Limpio) correspondió a un entrenamiento distinto. Como se mencionó anteriormente, el tercer dataset fue el que obtuvo los mejores resultados junto con su configuración. Con tan solo 26 épocas de entrenamiento, se logró alcanzar una precisión del 1.00% y una pérdida de 0.0058%. Además, se obtuvieron resultados sobresalientes en el conjunto de validación, con una precisión de 0.9286% y una pérdida de 0.3595%.

En contraste, los entrenamientos realizados con el Primer y Segundo Dataset arrojaron resultados regulares en el conjunto de entrenamiento, pero presentaron problemas de sobreajuste, ya que los resultados en el conjunto de validación fueron significativamente inferiores, así como se muestra en la tabla 5.

TABLE V
RESULTADOS DE LOS ENTRENAMIENTOS. PRECISIÓN Y PÉRDIDA EN TRES ENTRENAMIENTOS DE MOBILENET V3.

Entrenamiento	Precisión	Pérdida	Validación - Precisión	Validación - Pérdida
Entrenamiento 1	0.98	0.012	0.0012321	2.0108
Entrenamiento 2	0.65	0.73	0.005461	0.00324323
Entrenamiento 3	1.00	0.0058	0.9286	0.3595

El Entrenamiento 3 se destacó sobre los demás, generando el modelo con mejor desempeño. Por esta razón, se seleccionó este modelo como el más adecuado para ser implementado en el proyecto.

C. Entrenamiento YOLOv8 Small

La configuración que se usó para el modelo es la siguiente:

- **Modelo utilizado:** YOLOv8 Small (`yolo8s.pt`), que balancea precisión y velocidad, ideal para dispositivos móviles [19].
- **Tamaño de las imágenes:** 640 píxeles, para un balance entre resolución y eficiencia computacional.
- **Tamaño del lote:** 16 imágenes, adecuado para el hardware utilizado.

Como ya se mencionó para el entrenamiento de YOLOv8 Small, se utilizó exclusivamente el dataset titulado "Bird Detection Computer Vision Project", ya que este conjunto de datos fue seleccionado por su calidad y representatividad, diseñado específicamente para tareas de detección de aves en distintos entornos. No se aplicaron modificaciones adicionales al dataset, como técnicas de aumento de datos (*data augmentation*) o preprocesamientos específicos, ya que el dataset original incluía una adecuada variedad de escenarios y configuraciones. Esto permitió enfocarse directamente en la optimización del modelo YOLOv8 Small utilizando los parámetros predeterminados del dataset.

A lo largo del proyecto, se experimentó con diferentes números de épocas de entrenamiento para optimizar la precisión y eficiencia del modelo. En una primera fase, para minimizar el consumo de recursos computacionales, se utilizó la técnica de *Early Stopping* configurada con un límite de 10 épocas. Este parámetro detiene el entrenamiento si el

modelo no muestra mejoras en su desempeño después de 10 épocas consecutivas, permitiendo así ahorrar tiempo y recursos. Durante esta etapa, el entrenamiento finalizó en la época 67, alcanzando una precisión del 88.48%.

Posteriormente, se realizó un segundo experimento con el objetivo de explorar si el modelo podía lograr una mayor precisión. Para ello, se deshabilitó el *Early Stopping* y se estableció un límite de 100 épocas de entrenamiento. Los resultados obtenidos fueron ligeramente favorables, alcanzándose una precisión del 89.68%. Sin embargo, al analizar el impacto del entrenamiento adicional, se observó que el modelo no mostró una mejora significativa después de las primeras 67 épocas. Esto sugiere que, aunque el entrenamiento más prolongado permitió una leve mejora en métricas como *Precision* y *mAP@50-95*, el modelo ya había alcanzado un desempeño óptimo en etapas anteriores.

Tal como se presenta en la Tabla VI, el modelo entrenado con 100 épocas superó al de 67 épocas en métricas clave, como *Precision*, que alcanzó un valor de 89.68%, y *mAP@50-95*, con 60.59%. Estas métricas confirman que el modelo seleccionado cumple con los objetivos del proyecto, al ofrecer un desempeño sólido y eficiente en la identificación de aves.

TABLE VI
COMPARACIÓN DE MÉTRICAS ENTRE YOLOv8 SMALL (100 Y 67 ÉPOCAS). MÉTRICAS CLAVE PARA DOS CONFIGURACIONES DE YOLOv8 SMALL.

Métrica	100 épocas	67 épocas
Fitness	0.6372	0.6331
Precision (B)	0.8968	0.8848
Recall (B)	0.8591	0.8625
mAP@50 (B)	0.9185	0.9169
mAP@50-95 (B)	0.6059	0.6015

Por lo tanto el modelo YOLOv8 Small entrenado con 100 épocas fue seleccionado como la configuración final debido a su equilibrio entre precisión y eficiencia. Esta elección predispone a un desempeño robusto para la identificación de aves en entornos controlados, cumpliendo con los objetivos establecidos en el proyecto.

D. Sistema Integrado

El sistema integrado combina las capacidades de YOLOv8 Small y MobileNet V3 Large para realizar un proceso eficiente de identificación y clasificación de aves en dispositivos móviles. Este sistema sigue un flujo de trabajo optimizado, como se describe en la Figura 6, donde cada componente cumple un rol específico para garantizar resultados precisos.

El proceso comienza con el usuario, quien puede cargar o tomar una fotografía directamente desde la aplicación móvil. Esta imagen es enviada al modelo YOLOv8 Small, el cual realiza la detección de aves en la imagen. Si el modelo identifica un ave, genera una región delimitada en la imagen que contiene al objeto detectado. Este paso permite que el sistema recorte únicamente el área de interés, quitando elementos irrelevantes en la imagen, con la finalidad de que el modelo de clasificación analice solo la parte de interés de la imagen y no elementos irrelevantes.

La región recortada es entonces enviada al modelo MobileNet V3 Large, especializado en la clasificación de aves. Este modelo evalúa la región de interés y clasifica el ave en una de las cinco especies previamente definidas: Papamoscas Cardenalito, Papamoscas Pinero, Zacatonero Serrano, Carpintero de Arizona o Carbonero Mexicano.




Fig. 6. Flujo de trabajo. Proceso integrado desde captura e identificación del ave hasta la clasificación de la misma.

IV. RESULTADOS

Como se mencionó anteriormente, se seleccionaron la configuración y el dataset utilizados en el Entrenamiento 3, ya que este obtuvo los mejores resultados. Los resultados obtenidos durante este entrenamiento se presentan en la Tabla VII.

Como se puede observar, los resultados obtenidos son altamente favorables, alcanzando un 100% de precisión con una pérdida del 0.5% en el conjunto de entrenamiento. En el conjunto de validación, las métricas indican que no hay

TABLE VII
RESULTADOS FINALES MOBILENET V3 LARGE. PRECISIÓN Y PÉRDIDA TRAS 26 ÉPOCAS DE ENTRENAMIENTO.

Épocas	Precisión	Pérdida	Precisión_val	Pérdida_val
26	1.0000	0.0058	0.9286	0.3595

evidencia de sobreajuste en el modelo, logrando una precisión del 92% y una pérdida del 35%.

Además, se generó una matriz de confusión utilizando un nuevo conjunto de datos, diferente al dataset original, para validar aún más la precisión y funcionalidad del modelo. Este conjunto de datos consistió en 15,000 imágenes, distribuidas en 3000 imágenes por clase, como se muestra en la Figura 7.




Fig. 7. Matriz de confusión. Evaluación del modelo en cinco clases de aves.

De las 5 clases que se encuentran en la matriz de confusión encontramos el siguiente resultado:

- 1) **Carbonero Mexicano:** Correctas: 2338, Errores: 662.
- 2) **Carpintero de Arizona:** Correctas: 2895, Errores: 105.
- 3) **Papamoscas Cardenalito:** Correctas: 2939, Errores: 61.
- 4) **Papamoscas Pinero:** Correctas: 2992, Errores: 8.
- 5) **Zacatonero Serrano:** Correctas: 2865, Errores: 135.

La mayoría de las clases presentó un rendimiento sobresaliente al clasificar el nuevo conjunto de datos. Sin embargo, se observaron patrones específicos en las confusiones del modelo:

El **Carbonero Mexicano** tuvo la mayor cantidad de errores (662), siendo frecuentemente confundido con el **Zacatonero Serrano** y el **Papamoscas Piñero**. Estas confusiones se deben principalmente a similitudes en el tamaño y los patrones de coloración del plumaje. En particular, el Carbonero Mexicano y el Zacatonero Serrano comparten cuerpos pequeños y compactos, con plumajes predominantemente pardos o grises oscuros en las alas y la espalda. Además, el Zacatonero tiene

tonos apagados que, bajo ciertas condiciones de iluminación, pueden asemejarse a las áreas más oscuras del Carbonero. Por otro lado, el Papamoscas Pinero presenta proporciones corporales similares y tonos claros en el pecho que, en ciertas imágenes, pueden confundirse con las tonalidades del Carbonero, especialmente en situaciones donde la iluminación no resalta las diferencias en la coloración de la cabeza Figura 8.

Carbonero Mexicano: Clasificado incorrectamente en otras categorías



Fig. 8. Clasificación incorrecta de la clase Carbonero Mexicano

El **Papamoscas Cardenalito** fue confundido ocasionalmente con el **Papamoscas Piñero** y el **Zacatonero Serrano**. Estas confusiones se deben principalmente a que todas estas especies comparten cuerpos pequeños y compactos, con plumajes que incluyen tonos claros y marrones en varias partes del cuerpo. El Papamoscas Cardenalito, que se distingue por tonos rojizos en partes específicas de su plumaje, puede no ser identificado correctamente si estas áreas distintivas no están bien visibles o si la imagen tiene poca resolución. Asimismo, el Zacatonero Serrano y el Cardenalito tienen tonos claros en el pecho y las partes inferiores, lo que puede dificultar su distinción en imágenes con iluminación uniforme Figura 9.

Papamoscas Cardenalito: Clasificado incorrectamente en otras categorías



Fig. 9. Clasificación incorrecta de la clase Papamoscas Cardenalito

El **Papamoscas Pinero** mostró un rendimiento muy alto, con solo 8 errores, pero presentó confusiones con el **Carpintero de Arizona** y el **Carbonero Mexicano**. Estas confusiones se deben, en parte, a las similitudes en las proporciones corporales y los tonos marrones o beige que ambos comparten. El Carpintero de Arizona, por ejemplo, tiene un plumaje dorsal que puede parecerse al del Papamoscas Piñero en ángulos donde no es visible su cresta roja característica. Asimismo, el Carbonero Mexicano y el Papamoscas Piñero tienen tamaños similares y tonos oscuros en partes del plumaje, lo que puede ser un factor que contribuya a errores de clasificación Figura 10.

Papamoscas Pinero: Clasificado incorrectamente en otras categorías



Fig. 10. Clasificación incorrecta de la clase Papamoscas Pinero

El **Carpintero de Arizona** presentó confusiones principalmente con el **Papamoscas Piñero** y el **Carbonero Mexicano**. Estas confusiones pueden deberse a que, en ciertos ángulos, las características distintivas del Carpintero, como su cresta roja y el pico largo, no son visibles, lo que lo hace parecer similar al Papamoscas Piñero, que tiene un plumaje pardo o beige en la espalda. Por otro lado, el Carbonero Mexicano y el Carpintero de Arizona comparten cuerpos compactos y proporciones similares, con plumajes oscuros en las alas o la cabeza. Estas similitudes, combinadas con variaciones en la iluminación o ángulos de captura, pueden explicar las confusiones observadas Figura 11.

Carpintero de Arizona: Clasificado incorrectamente en otras categorías




Fig. 11. Clasificación incorrecta de la clase Papamoscas Pinero

El **Zacatonero Serrano** mostró confusiones menores con el **Papamoscas Piñero** y el **Carpintero de Arizona**. Estas confusiones están relacionadas con los patrones de color similares en el plumaje dorsal. Tanto el Zacatonero como el Papamoscas Piñero tienen plumajes claros o pardos en las partes inferiores y tamaños pequeños. Además, las proporciones corporales similares de estas especies pueden llevar al modelo a clasificarlas incorrectamente en ciertos casos. En cuanto al Carpintero de Arizona, el Zacatonero y este comparten tonalidades marrones en el plumaje dorsal que, en ausencia de detalles claros como el pico largo del Carpintero, pueden confundir al modelo Figura 12.

Zacatonero Serrano: Clasificado incorrectamente en otras categorías



Fig. 12. Clasificación incorrecta de la clase Papamoscas Pinero

Adicionalmente, a partir de la matriz de confusión generada con el nuevo conjunto de datos, se calcularon las métricas

esenciales para evaluar el desempeño del modelo. En general, se obtuvo una precisión del 93% al clasificar las 15,000 imágenes, como se detalla en la Tabla VIII.

TABLE VIII
RESULTADOS DE LA MATRIZ DE CONFUSIÓN. PRECISIÓN Y RECALL DE MOBILENET V3 EN CINCO CLASES.

Clase	Precisión	Recall	F1-Score	Support
Carbonero Mexicano	0.99	0.78	0.87	3000
Carpintero de Arizona	0.97	0.96	0.97	3000
Papamoscas Cardenalito	1.00	0.97	0.99	3022
Papamoscas Piñero	0.81	1.00	0.90	3000
Zacatonero Serrano	0.94	0.95	0.95	3000
Exactitud	0.93 (Accuracy)			
Promedio Macro	0.94	0.93	0.93	15022
Promedio Ponderado	0.94	0.93	0.93	15022

A. Resultados obtenidos de YOLOv8 Small

El conjunto de datos utilizado para entrenar la red neuronal YOLOv8 Small incluyó una carpeta de validación diseñada específicamente para evaluar el desempeño del modelo. Las métricas obtenidas a partir de estas pruebas reflejan un 89.67% de precisión, lo que indica un alto nivel de exactitud en la identificación de aves en las imágenes de validación. Asimismo, se alcanzó un recall de 85.91%, lo que demuestra la excelente capacidad del modelo para capturar la mayoría de las instancias relevantes. Además, las métricas mAP@50 (91.85%) y mAP@50-95 (60.59%) confirman que el modelo mantiene un desempeño sólido, incluso bajo umbrales de evaluación más estrictos.

TABLE IX
RESULTADOS DEL MODELO YOLOv8 SMALL. MÉTRICAS CLAVE PARA LA IDENTIFICACIÓN DE AVES.

Parámetro	Valor
Fitness	0.637
Precisión	0.897
Recall	0.859
mAP@50	0.919
mAP@50-95	0.606
Velocidades (segundos)	
Preprocesamiento	0.133
Inferencia	0.839
Postprocesamiento	0.828

Como observamos en la tabla IX, YOLOv8 Small presentó buen rendimiento a la hora de identificar aves en el conjunto de datos de validación, siendo así que cumple con su tarea designada.


B. Prueba en entornos reales

Como paso final, los modelos fueron preparados y optimizados para su uso en dispositivos móviles mediante TensorFlow Lite. Esta herramienta se encarga de optimizar los modelos al reducir su tamaño de archivo, eliminando pesos y operaciones innecesarias. De este modo, se logra que el modelo sea más

liviano y eficiente, facilitando su implementación en entornos móviles con recursos limitados [20].

A continuación se presentaran las pruebas en entornos reales:

← Muestreo



Nombre del muestreo: _____
Nombre coloquial del ave: _____
Fecha: 10/12/2024
Hora: 13:48:38
Coordenadas: 22.7837811, -102.6150134

(a) Ave No Detectada

← Muestreo



Nombre del muestreo: _____
Nombre coloquial del ave: Zacatonero Serrano
Fecha: 26/11/2024
Hora: 17:40:51
Coordenadas: 22.7639725, -102.5442291

(b) Zacatonero Serrano

← Muestreo



Nombre del muestreo: Hola
Nombre coloquial del ave: Papamoscas Piñero
Fecha: 20/10/2024
Hora: 19:40:31
Coordenadas: 22.7639773, -102.544138

(c) Papamoscas Piñero

← Muestreo



Nombre del muestreo: _____
Nombre coloquial del ave: Papamoscas Piñero
Fecha: 16/12/2024
Hora: 02:55:53
Coordenadas: 22.7639759, -102.5441244

(d) Papamoscas Piñero

Fig. 13. Pruebas en entornos reales. Ejemplos de clasificación con la aplicación "IdBird".

Es importante mencionar que estas tecnologías fueron implementadas en una aplicación llamada "IdBird". La interfaz de la aplicación, en sus diferentes etapas, se muestra en la Figura 13. Como se observa en dicha figura, si el modelo de clasificación (en este caso, MobileNet) recibe una imagen de un ave que no pertenece a las cinco clases previamente definidas, como una paloma, esta no será clasificada. Las demás imágenes en la figura ilustran el correcto funcionamiento de las tecnologías implementadas, YOLOv8 Small y MobileNet V3 Large, ambas convertidas a TensorFlow Lite. Esto permite que las aves sean clasificadas adecuadamente según la clase correspondiente.

V. CONCLUSIÓN Y TRABAJOS FUTUROS

Al comparar este trabajo con los proyectos revisados en el estado del arte, se identifican diferencias importantes que

resaltan los aportes de esta propuesta. Por ejemplo, algunos trabajos, como los que utilizan YOLOv5 junto con modelos de clasificación como VGG19 e Inception V3, ofrecen enfoques robustos para la detección y clasificación. Sin embargo, estas soluciones suelen depender de grandes conjuntos de datos y requieren recursos computacionales altos, lo que dificulta su implementación en dispositivos móviles.

Por otro lado, proyectos que emplean YOLO o Faster R-CNN en drones o cámaras estacionarias son efectivos para la detección en hábitats amplios, pero no incluyen modelos de clasificación, lo que limita su alcance a la identificación de objetos sin diferenciar especies. Este sistema, al integrar YOLOv8 Small para la detección y MobileNet V3 Large para la clasificación, aborda ambos problemas de manera simultánea, logrando identificar aves y clasificarlas en cinco especies específicas. Esta combinación hace que la solución sea más completa y práctica para investigaciones ambientales.

Un aspecto clave es la incorporación de YOLOv8 Small, una versión más ligera y optimizada para dispositivos móviles en comparación con YOLOv5 o YOLOv7 [21], lo que permite un flujo de trabajo más adaptable a dispositivos con recursos limitados. Además, la integración de un modelo de clasificación robustece el sistema, ampliando sus capacidades frente a soluciones que solo implementan detección.

En conclusión, la implementación de las tecnologías YOLOv8 Small y MobileNet V3 Large en la aplicación "IdBird" demuestra ser una solución eficiente y práctica para la identificación y clasificación de aves en dispositivos móviles. El sistema es capaz de distinguir entre especies específicas con precisión, destacándose por su portabilidad y bajo impacto en el entorno natural. Este trabajo sienta las bases para futuras expansiones, como la integración en la nube, que potenciarán su capacidad para procesar más datos y especies.

VI. REFERENCIAS

[1] N. Pérez-Valadez, "Adiciones a la avifauna del estado de Zacatecas," *Huitzil*, vol. 17, no. 2, pp. 175-183, 2016.

[2] Rust, N., Jannuzi, B. (2022). Identifying Objects and Remembering Images: Insights From Deep Neural Networks. *Current Directions in Psychological Science*, 31, 316 - 323. <https://doi.org/10.1177/09637214221083663>.

[3] , S., Lu, H., Liu, J., Zhu, Y., Sang, P. (2024). LAYN: Lightweight Multi-Scale Attention YOLOv8 Network for Small Object Detection. *IEEE Access*, 12, 29294-29307. <https://doi.org/10.1109/ACCESS.2024.3368848>.

[4] Lee, V., Jiménez, A., Belmonte, I., González, E. (2023). Image Recognition System for Bird Sampling in the City of Zacatecas. 2023 12th International Conference On Software Process Improvement (CIMPS), 126-135. <https://doi.org/10.1109/CIMPS61323.2023.10528852>.

[5] (2022). Influence Analysis of Image Feature Selection Techniques Over Deep Learning Model. *International Journal of Emerging Trends in Engineering Research*. <https://doi.org/10.30534/ijeter/2022/031072022>.

[6] Vo, H., Thien, N., Mui, K. (2023). Bird Detection and Species Classification: Using YOLOv5

and Deep Transfer Learning Models. *International Journal of Advanced Computer Science and Applications*. <https://doi.org/10.14569/ijacsa.2023.01407102>.

[7] Zhong, M., Taylor, R., Bates, N., Christey, D., Basnet, H., Flippin, J., Palkovitz, S., Dodhia, R., Ferres, J. (2021). Acoustic detection of regionally rare bird species through deep convolutional neural networks. *Ecol. Informatics*, 64, 101333. <https://doi.org/10.1016/J.ECOINF.2021.101333>.

[8] Vo, H., Thien, N., Mui, K. (2023). Bird Detection and Species Classification: Using YOLOv5 and Deep Transfer Learning Models. *International Journal of Advanced Computer Science and Applications*. <https://doi.org/10.14569/ijacsa.2023.01407102>.

[9] Dawasari, H., Bilal, M., Moinuddin, M., Arshad, K., Assaleh, K. (2023). DeepVision: Enhanced Drone Detection and Recognition in Visible Imagery through Deep Learning Networks. *Sensors (Basel, Switzerland)*, 23. <https://doi.org/10.3390/s23218711>.

[10] Mirugwe, A., Nyirenda, J., Dufourq, E. (2022). Automating Bird Detection Based on Webcam Captured Images using Deep Learning. *EPiC Series in Computing*. <https://doi.org/10.29007/9fr5>.

[11] Steen, R. (2017). Bird monitoring using the smartphone (iOS) application Videography for motion detection. *Bird Study*, 64, 62 - 69. <https://doi.org/10.1080/00063657.2016.1271772>.

[12] Mpouziotas, D., Karvelis, P., Stylios, C. (2024). Advanced Computer Vision Methods for Tracking Wild Birds from Drone Footage. *Drones*. <https://doi.org/10.3390/drones8060259>.

[13] Vo, H., Thien, N., Mui, K. (2023). Bird Detection and Species Classification: Using YOLOv5 and Deep Transfer Learning Models. *International Journal of Advanced Computer Science and Applications*. <https://doi.org/10.14569/ijacsa.2023.01407102>.

[14] Steen, R. (2017). Bird monitoring using the smartphone (iOS) application Videography for motion detection. *Bird Study*, 64, 62 - 69. <https://doi.org/10.1080/00063657.2016.1271772>.

[15] Mupparaju, S., Thotakura, S. R., Venkata Rami Reddy, C. (2024). A Review on YOLOv8 and Its Advancements. In *Data Intelligence and Cognitive Informatics* (pp. 529-545). Springer. https://doi.org/10.1007/978-981-99-7962-2_39

[16] birddetecitonavisent. (2024, April). bird-detection Dataset. Roboflow Universe. Roboflow. Retrieved January 5, 2025, from <https://universe.roboflow.com/birddetecitonavisent/bird-detection-kzmpu>

[17] birddetecitonavisent. (2024, April). bird-detection Dataset. Roboflow Universe. Roboflow. Retrieved January 5, 2025, from <https://universe.roboflow.com/birddetecitonavisent/bird-detection-kzmpu>

[18] Ejaz, M. (2024). VGG16 and MobileNet Performance Evaluation on Edge Device in Self-Driving Car Technology. 2024 IEEE International Conference on Auto-

matic Control and Intelligent Systems (I2CACIS), 12-17.
<https://doi.org/10.1109/I2CACIS61270.2024.10649882>.

[19] Mupparaju, S., Thotakura, S. R., Venkata Rami Reddy, C. (2024). A Review on YOLOv8 and Its Advancements. In Data Intelligence and Cognitive Informatics (pp. 529-545). Springer. https://doi.org/10.1007/978-981-99-7962-2_39

[20] Liu, L., Ke, C., Lin, H., Xu, H. (2022). Research on Pedestrian Detection Algorithm Based on MobileNet-YoLo. Computational Intelligence and Neuroscience, 2022. <https://doi.org/10.1155/2022/8924027>.

[21] Lou, H., Duan, X., Guo, J., Liu, H., Gu, J., Bi, L., Chen, H. (2023). DC-YOLOv8: Small-Size Object Detection Algorithm Based on Camera Sensor. Electronics. <https://doi.org/10.3390/electronics12102323>.